Inteligencia Artificial y Aprendizaje Automático

Actividad Semanal:
Evaluación de un Sistema de Predicción de Precios de Vivienda

Maestría en Inteligencia Artificial Aplicada
Tecnológico de Monterrey
Prof. Luis Eduardo Falcón Morales

Nombres: _____

Matrículas: _____

Esta Tarea se resuelve por equipos. Tendrán dos semanas para resolverla.

Introducción

El mercado de bienes raíces es enorme y muy complejo. En el pasado, para saber cuánto valía una propiedad, los expertos las comparaban de forma manual. Esto a menudo causaba errores, ya que los seres humanos no podemos analizar cientos de detalles al mismo tiempo.

Hoy en día, gracias a la tecnología, existen programas automáticos que calculan el precio de una casa en segundos. Para hacerlo, analizan tanto las características de la propiedad (como su tamaño, materiales y comodidades) como su ubicación.

Para los expertos en datos, el gran reto es elegir la mejor inteligencia artificial para hacer estos cálculos. Su objetivo es encontrar el equilibrio perfecto: lograr que el precio estimado sea lo más exacto posible, que la computadora no tarde demasiado en procesarlo y que sea fácil explicar cómo se llegó a ese resultado.

Problema

El objetivo técnico de esta actividad es desarrollar, evaluar y comparar críticamente varias arquitecturas de aprendizaje automático (Regresión Lineal con o sin algún tipo de Regularización, Árbol de Decisión, Bosque Aleatorio, XGBoost, Red Neuronal Multicapa y Máquina de Vector Soporte) para predecir de manera estática el precio de cierre de las viviendas, cuya variable se define como “SalePrice”.

Para ello, usaremos el conjunto de datos del reto de Kaggle llamado “House Prices – Advanced Regression Techniques” y que encuentras en la siguiente liga:

https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/overview

El objetivo de esta actividad no será exactamente el mismo que el solicitado en el reto de Kaggle, por lo que deberás tomar en cuenta las siguientes restricciones.

Restricciones

- El problema simulará una valuación de las casas en un plano temporal estático, por lo que no deberán usarse las variables de tendencias cronológicas absolutas. Por lo tanto:
    - Se debe eliminar la variable del año de venta YrSold.

- Transformar las variables de año calendario —YearBuild (año en que se construyó) y YearRemodAdd (año en que se remodeló)— en variables numéricas de edad relativas al presente año actual, 2026. Llamarlas AgeHouse y AgeRemod, respectivamente.
- Identifiquen cuál consideran es la mejor decisión para la variable MoSold (mes en que se vendió la casa): dejarla como está, de tipo numérico; eliminarla; transformarla a tipo categórico desde el inicio; transformarla numéricamente de manera cíclica mediante las funciones seno y coseno.

Una vez descargado el conjunto de datos responde a las siguientes preguntas:

1. Justificar la decisión tomada en la variable "YrSold".
2. Justificar la decisión tomada con las variables "YearBuild" y "YearRemodAdd". Además, una vez transformadas en las nuevas variables, ¿deben seguir conservándose como variables de entrada o debemos eliminarlas? ¿Por qué?
3. Justificar la decisión tomada con la variable "MoSold". En caso de que la decisión haya sido transformarla de alguna manera, ¿debemos eliminar la variable original a continuación? ¿Por qué?
4. Realizar un análisis y procesamiento de los datos como consideren sea lo más adecuado. En particular, realicen una limpieza de datos; imputación sobre datos perdidos (media, mediana o moda); decidan qué transformaciones aplicar sobre las variables numéricas, nominales, ordinales, o cíclicas (en dado caso). Cada una de estas decisiones se espera sea la mejor de todas las consideradas. Justificar las decisiones tomadas.
5. En particular, expliquen la decisión tomada con los datos perdidos de las variables "PoolQc" y "GarageType".
6. Para las variables nominales en las cuales hayan decidido aplicar la transformación One-Hot-Encoding, explicar si debe hacerse diferencia en relación con el valor del hiperparámetro "drop" cuando se usa en un modelo basado en árboles, o con en el resto de los modelos.
7. Realizar una partición en entrenamiento (train), validación (val) y prueba (test) con el porcentaje que consideren más adecuado. En dado caso, si deciden usar Validación-Cruzada (con las secciones/folds que mejor consideren), entonces se entiende que aquí solo sería necesario particionarlo en dos.
8. Con relación a la métrica de la raíz del error cuadrático medio RMSE, obtener el desempeño del modelo base o ingenuo.
9. Deberán llevar a cabo el entrenamiento y ajuste de hiperparámetros de los modelos considerando como métrica de referencia la RMSE y evitando filtrado de información. Lleven el entrenamiento y ajuste para cada modelo por separado y mostrando en cada caso la gráfica de curvas de aprendizaje. Sin embargo, mostrar de manera tabular también el resultado de RMSE, MAE, R^2, MAPE y el tiempo de entrenamiento.
    a. Modelo(s) de regresión lineal múltiple.
    b. Árbol de decisión.
    c. Bosque Aleatorio.
    d. XGBoost.
    e. Red Neuronal de Perceptrón Multicapa (MLP).
    f. Máquina de Vector Soporte (SVM).
10. Con base al mejor modelo obtenido realizar un análisis de factores, con la interpretación en base al contexto del problema.

11. Considerando como métrica la suma RMSE+MAE, selecciona los tres mejores modelos obtenidos. ¿Qué ventajas podría traer el considerar esta suma como una métrica? Explicarlo en el contexto del problema e indicando sus ventajas y desventajas.
12. Investigar en qué consisten las técnicas VotingRegressor y StackingRegressor de los llamados métodos o modelos de aprendizaje conjuntos (ensemble learning).
13. Con los tres mejores modelos obtenidos y la métrica RMSE, implementar el método de votación con VotingRegressor de sklearn.
14. Con los tres mejores modelos obtenidos y la métrica RMSE, implementar el método de apilamiento con StackingRegressor de sklearn.
15. Comparar estos dos resultados con los tres mejores modelos utilizados. ¿Con base a los resultados obtenidos, crees que sería conveniente utilizar alguno de estos modelos conjuntos en lugar de alguno de los individuales?
16. Realizar dos reportes finales sobre qué decisión tomar:
    a. Un reporte para tu equipo técnico indicando las decisiones que se deben tomar con base a las métricas, ajuste de los modelos, costo computacional, mantenimiento de la solución.
    b. Un reporte para el director de la empresa inmobiliaria con base a los beneficios, riesgos y costos y de manera no técnica.
17. Incluyan sus conclusiones de la actividad.